

ML 과제 Report

먼저, Kaggle의 Credit Card Fraud Detection 데이터셋(creditcard.csv)을 불러와 구조를 확인하였다. 전체 데이터는 총 284,807건, 31개 컬럼 (Time, V1~V28, Amount, Class)으로 구성되었다. 결측치는 존재하지 않았다. Class 비율을 살펴보았을 때, 정상 거래는 약 99.8%, 사기 거래는 0.17%이며 건수로 보면 정상 거래는 284315, 사기 거래는 492건으로 극단적인 클래스 불균형 데이터임을 확인하였다. 사기 거래(Class=1) 492건은 전부 유지하고 정상 거래(Class=0)는 10,000건만 무작위로 샘플링을 진행하였다. 데이터는 총 10,492건의 데이터프레임으로 구성되었다. 샘플링을 진행하고 Class 비율을 보았을 때, 사기 거래 비율이 0.17%에서 4.69%로 높아졌다. Amount 변수는 다른 변수들과 스케일이 크게 달라 표준화를 진행하여 Amount_Scaled 변수로 대체하고 원본 Amount 컬럼은 삭제하였다. 이후 Class를 종속변수 y로, 나머지 변수를 독립변수 X로 분리하였다.

트레이닝 셋과 테스트셋을 8:2로 분할하였다. 클래스 불균형이 존재하는 데이터이므로 stratify=y 옵션을 적용하여 분할 전후 클래스 비율이 동일하게 유지되도록 하였다. 사기 거래가 정상 거래에 비해 압도적으로 적기 때문에, 소수 클래스의 비율을 맞춰주기 위해 SMOTE(Synthetic Minority Over-sampling Technique) 기법을 사용하였다. 사기 거래가 정상 거래에 비해 압도적으로 적기 때문에, 모델이 정상만 예측해도 정확도(accuracy)는 높게 나오는 착시가 생길 수 있다. 이 경우 실제로 중요한 사기 거래를 거의 탐지하지 못하는 모델이 만들어질 위험이 크다. SMOTE 기법은 소수 클래스 샘플들 사이에 새로운 합성 샘플을 생성함으로써, 학습 데이터의 클래스 균형을 맞추고, 모델이 소수 클래스의 결정 경계를 더 잘 학습할 수 있게 하기에 본 데이터에서 사용하기 적합한 샘플링 기법이다. 다만, 주의할 점은 SMOTE는 반드시 학습 데이터에만 적용해야 한다. 테스트 데이터에 적용하면, 실제와 다른 분포로 평가하게 되어 성능이 과대평가 되기 때문이다.

모델 학습에는 3개 모델을 선정하여 학습하고 결과를 비교하였다. 사용한 모델은 Logistic Regression, Random Forest, Gradient Boosting이다. 데이터가 선형인지, 비선형인지 알 수 없기에 선형 모델인 Logistic Regression과 비선형 데이터일 경우 자주 사용하는 Random Forest와 성능 향상을 위해 오류를 수정하며 진행하는 Gradient Boosting을 선정하였다. 3개의 모델의 성능을 정리하면 다음과 같다.

Logistic Regression은 0.9286으로 Recall이 가장 높지만 F1(정밀도-재현율 균형)은 상대적으로 낮았고, Random Forest는 Recall은 세 모델 중 가장 낮지만 Precision이 높아 0.9053으로 F1이 가장 우수했다. PR-AUC는 세 모델이 비슷한 수준(약 0.95)이었다. Gradient Boosting은 Random Forest보다 복잡한 모델이지만 뚜렷한 성능 향상을 보이지

못했다.

종합적으로 F1-score가 가장 높은 Random Forest를 최종 모델로 선정하고, 이후 하이퍼파라미터 튜닝 및 threshold 조정을 진행하였다. 최적의 하이퍼파라미터를 찾고, 튜닝을 진행한 결과 기존의 결과와 동일하게 나왔다. 이미 충분히 설득력 있는 값을 가졌다고 설명할 수 있다. Threshold의 경우 Precision이 0.9348에서 0.9884으로 크게 상승하면서 F1도 0.9053에서 0.9239로 개선되었다. 하지만, Recall은 0.8776에서 0.8673으로 소폭 하락하였다.

Threshold를 조정한 Random Forest 모델은 Class 0에서 Recall 0.995, F-1 score 0.9965, PR-AUC 0.9533을 달성하였고 Class 1에서 Recall 0.8673, F-1 score 0.9239, PR-AUC 0.9533을 달성하였다. 최종적으로 위 모델은 Class 0, Class 1 모두에서 목표로 제시된 $\text{Recall} \geq 0.80$, $\text{F1} \geq 0.88$, $\text{PR-AUC} \geq 0.90$ 기준을 모두 충족하였다.